



CONTROLE AUTOMATIZADO BIODIGESTOR

Herdney S. dos Santos.
Engenharia da Computação.
Centro Universitário Internacional.
herdney@hotmail.com

Leila Fabíola Ferreira.
Engenharia da Computação.
Centro Universitário Internacional.
leilafabiola89@gmail.com

Prof. Dr. Marcos B. Proença
Engenharia de Produção
Centro Universitário Internacional
marcos.p@uninter.com

GRUPO DE TRABALHO ENGENHARIA, TECNOLOGIA E INOVAÇÃO



Resumo

O processo de produção de Biogás é influenciada pela temperatura, ph e monóxido de carbono. Essas variáveis devem ter certas condições que favorecem a produção, onde a temperatura deve estar entre 40 e 60° C, ph entre 6 e 7 e o monóxido de carbono acima de 75 partes por milhões. Quaisquer das variáveis fora dessas condições comprometem todo o processo. Para realizar esse controle, atualmente utiliza-se o aplicativo de smartphone Blynk para monitorar, controlar e atuar sobre os sensores acoplados ao biodigestor. Contudo esse controle necessita de um operador, que deve proceder o monitoramento e, caso as condições não estejam nas condições ideais, acionar os controles através do Blynk. Contudo, o processo de produção leva em torno de 30 dias e o biodigestor deve permanecer 24 horas/dia ligado, tornando suscetível a falhas o monitoramento por intervenção humana. Portanto, o projeto de pesquisa tem relevância ao propor o controle por Inteligência Artificial, onde o algoritmo fará a comparação das leituras realizadas pelos sensores do biodigestor e as condições que favorecem a produção. Caso as leituras estejam fora das condições ideais, o próprio algoritmo irá tomar a decisão e acionar os atuadores dos sensores. Diante o exposto, o presente projeto tem como objetivo desenvolver algoritmo para realizar o monitoramento e controle automatizado de um biodigestor.

O biogás tem origem de um processo biológico e que ocorre anaerobicamente e pode ser influenciada pela temperatura, valor de ph, e monóxido de carbono. A geração de biogás ocorre no equipamento biodigestor de processo aeróbico/anaeróbico, onde as variáveis citadas podem ser controladas para manter as condições ideais para a produção.

Para auxiliar no processo de controle dessas variáveis foi desenvolvido algoritmo árvore de decisão que classifica as leituras capturadas pelos sensores acoplados ao biodigestor como “anormais”, quando quaisquer das variáveis estão fora das condições estipuladas, e como “normais”, quando todas as variáveis estão em condições favoráveis para a produção do biogás.

Quando as leituras são classificadas como anormais, o algoritmo de monitoramento e controle irá acionar os atuadores dos sensores, ligando os motores dos respectivos sensores para manter as condições ideais para a produção sem a necessidade da intervenção humana.

Para desenvolver o algoritmo da árvore de decisão, que é uma técnica de aprendizado supervisionado, foi elaborada uma base de treinamento com 10.000 registros pré-classificados. O treinamento gerou o grafo de árvore de decisão, onde o resultado principal de entropia (0.205) apontou a pressão como o previsor mais relevante.

Devido a fase de implantação do biodigestor, o mesmo não está em produção de leitura real, logo elaborou-se uma base aleatória de 100 registros que simulam as leituras dos sensores. Essa base de dados foi passada para o algoritmo realizar a classificação.

A avaliação do algoritmo, através da medida de acurácia onde é medido o nível de confiança da precisão, retornou um índice de 93%, ou seja, das 100 leituras realizadas, 93 delas foram classificadas corretamente. Corroborando com a medição, elaborou-se a matriz de confusão onde o algoritmo classificou 97 leituras como “anormais” e 3 como “normais”. Dentre as 97 leituras “anormais”, o algoritmo classificou corretamente 93 leituras (anormais) e incorretamente 4 leituras (normais). Já as 3 leituras “normais” foram classificadas incorretamente como “anormais”.

Os próximos passos desta pesquisa é implementar o processamento paralelo do algoritmo de monitoramento e controle, que atualmente é sequencial. Com essa



implementação, as variáveis serão comparadas em paralelo e os atuadores serão acionados assim que as condições estiverem fora dos padrões ideais.

Palavras-chave: Biogás, Biodigestor, Árvore de decisão, Controle automatizado.



INTRODUÇÃO

A utilização de técnicas de inteligência artificial já faz parte da realidade no mundo contemporâneo e está presente nas mais diversas aplicações utilizadas na indústria, jogos computacionais, automóveis e outros dispositivos, sendo uma ferramenta muito poderosa para aplicações em sistemas computacionais.

O método da árvore de decisão e regressão pode ser formulado como um problema de procura em um espaço de possíveis soluções, que poderão ser utilizadas como parâmetro para determinado sistema. No caso aplicado, o sistema em questão é um biodigestor de bancada, equipamento utilizado para o processo de produção e armazenamento de gases advindos da decomposição de compostos orgânicos.

Os dados são obtidos através dos sensores acoplados ao biodigestor, realizando a leitura da temperatura, ph, monóxido de carbono e o metano, com a finalidade de monitorar se as condições que favorecem a produção de metano estão dentro da normalidade. Também mede a pressão, para acionar o sistema de segurança, evitando que a pressão interna exceda o limite de resistência mecânica do equipamento. Caso ocorra alguma anomalia em uma das condições, o sistema irá acionar os atuadores para normalizar a condição afetada, evitando o risco de perder todo o processo de produção.

O presente trabalho está dividido em quatro seções: introdução e referencial teórico, onde é descrito o conhecimento necessário para a implantação e a realização dos testes; metodologia, descrevendo as etapas dos procedimentos adotados para coleta e o monitoramento das condições ideais para a produção de gás metano; considerações finais, onde são descritos os resultados obtidos bem como os próximos passos desta pesquisa.



REFERENCIAL TEÓRICO

O biogás tem origem de um processo biológico que, conforme CREMONEZ et al. (2013), ocorre na ausência de oxigênio molecular, onde se tem consórcios de diferentes tipos de microrganismos interagindo estreitamente para promover a transformação de composto orgânico complexos, em simples. Já ALVES, MELO e WISNIEWSKI (1980) diz que o biogás é proveniente da fermentação anaeróbica da matéria orgânica e constitui-se de uma mistura de metano, dióxido de carbono, hidrogênio e traços de outros gases. De acordo com o FACHAGENTUR NACHWACHSENDE ROHSTOFFE – FNR (2010), traduzido por ZATTAR, a composição de metano no biogás é de 50% a 75% em volume, dióxido de carbono varia entre 25% a 50% em volume, tendo ainda pequenas quantidades de oxigênio, amônia e outros gases residuais.

Segundo KARLSSON et al (2014), se o biogás é purificado, ou seja, constituído apenas por metano, pode ser utilizado para geração de energia e como combustível veicular.

O processo de formação do biogás se divide em várias etapas, porém as etapas principais e geralmente consideradas são: hidrólise; acidogênese; acetogênese e por fim a metanogênese.

A geração do biogás pode ser influenciada pela temperatura, oxigênio, valor do pH, disponibilidade de nutrientes para os microrganismos e inibidores (para retardar o processo de produção).

A geração do biogás ocorre no biodigestor, que é um equipamento utilizado nesse processo de produção. (FERNANDES, 2012). Esses biodigestores podem ser classificados pela forma com a qual é fornecida a biomassa, que segundo FERNANDES (2012) são: sistema intermitente e sistema contínuo.

No sistema intermitente ou batelada, de acordo com SUZUKI (2012) “a alimentação no biodigestor é realizada apenas uma única vez, e todo o processo de biodigestão é realizada sem novas alimentações”. Já o sistema contínuo a alimentação do biodigestor “permanece constante ao longo do tempo”. (FERNANDES, 2012).



De acordo com COPPIN (2017), "A Inteligência Artificial é o estudo de sistemas que agem de um modo que a um observador qualquer pareceria ser inteligente".

Os fundamentos da Inteligência Artificial, de acordo com RUSSELL e NORVIG (2013), baseiam-se em diversas áreas de conhecimento, tais como: a filosofia, a matemática, a economia, a neurociências, a psicologia, a engenharia de computadores, a teoria de controle e a cibernética e a linguística.

Segundo RUSSELL e NORVIG (2013), o primeiro trabalho de inteligência artificial foi realizado por Warren McCulloch e Walter Pitts (1943), baseando-se nas seguintes fontes: o conhecimento da filosofia básica e da função dos neurônios no cérebro, a análise da lógica proposicional de Russell e Whitehead e a teoria da computação de Turing. Esses pesquisadores propuseram um modelo de neurônios artificiais caracterizados pelo estado de "ligado" e "desligado".

Alguns anos depois, Donald Hebb (1949) demonstrou uma regra de atualização simples para modificar as intensidades de conexões entre os neurônios e é conhecida até hoje como aprendizado de Hebb.

Um dos influenciadores da Inteligência Artificial foi John McCarthy, o qual reuniu pesquisadores interessados em teoria de autômatos, redes neurais e estudo da inteligência. McCarthy almejava descobrir como fazer com que as máquinas usassem uma linguagem, a partir de abstrações e de conceitos, resolvessem os tipos de problemas reservados aos seres humanos e se aperfeiçoassem.

O McCarthy definiu a linguagem de alto nível Lisp como uma linguagem de programação de Inteligência Artificial.

Um dos exemplos utilizados até hoje, chamados na época de micromundo, é o mundo de blocos, cuja tarefa é reorganizar os blocos de certa maneira, utilizando a mão de um robô que pode erguer um bloco de cada vez.

Os métodos de aprendizado de Hebb foram aperfeiçoados por Bernie Widrow, e o denominou como adelines, e por Frank Rosenblatt com seu teorema da convergência do perceptron, que determina que "o algoritmo de aprendizagem podia ajustar seus pesos de conexão de um perceptron



corresponderem a quaisquer dados de entrada, desde que existisse tal correspondência”. (RUSSELL e NORVIG, 2013)

Outro personagem da abordagem simbólica é Newell, que criou o Solucionador Geral de Problemas (General Problem Solver), que de acordo com GRANATYR (2016), a ideia básica do GPS era resolver vários tipos de problemas utilizando o mesmo mecanismo de raciocínio. Portanto a inteligência artificial foi categorizada como Inteligência Artificial Simbólica e Inteligência Artificial Conexionista.

Inteligência Artificial Simbólica é onde o conhecimento sobre o problema precisa ser definido manualmente no sistema para que ele possa raciocinar e tomar as decisões, sendo exemplo de IA simbólica os sistemas especialistas. Já a Inteligência Artificial Conexionista é baseada na simulação dos componentes do cérebro (modelagem da inteligência humana) e o principal exemplo são as redes neurais. (GRANATYR, 2016).

Dentro a Inteligência Artificial Simbólica, os estudos da aprendizagem de máquina estão bem avançados, e de acordo com CARVALHO et al (2011, p. 3 apud MITCHELL, 1997), é a capacidade de melhorar o desempenho na realização de alguma tarefa por meio da experiência. E para melhorar esse desempenho utiliza a indução, que conforme LUGER (2013) os dados de treinamento são apenas um subconjunto de todos os exemplos do domínio, conseqüentemente, qualquer conjunto de treinamento pode dar suporte a muitas generalizações diferentes.

Para melhorar esse desempenho as máquinas podem aprender de forma supervisionada, não-supervisionada ou por reforço. De acordo com COPPIN (2017), no aprendizado supervisionado aprendem ao serem apresentados a dados de treinamento pré-classificados, enquanto no aprendizado não supervisionado aprendem sem qualquer intervenção humana e por fim no aprendizado com reforço receberá um reforço positivo ao operar corretamente e um reforço negativo ao operar incorretamente. Este projeto utiliza o aprendizado supervisionado.

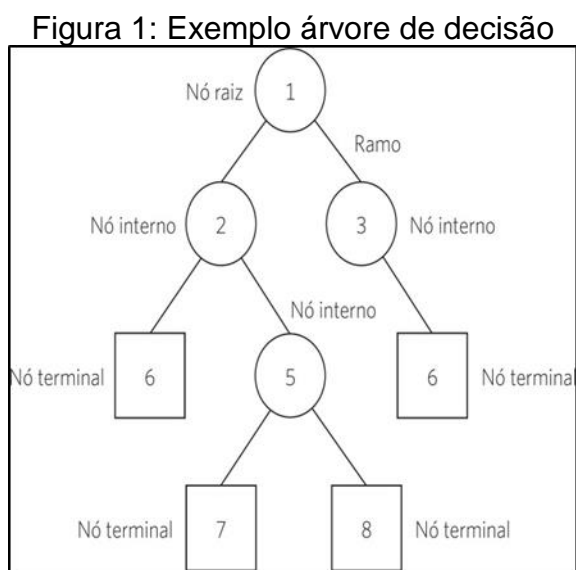
No processo de aprendizado supervisionado para realizar os treinamentos é necessário representar os problemas do mundo real de forma que o computador possa entender, e conforme COPPIN (2017), a rede



semântica é uma representação comumente utilizada em Inteligência Artificial que é um grafo consistindo em vértices que são conectados por arestas. Enquanto a Herança consiste nos relacionamentos que, segundo COPPIN (2017), especificam as propriedades de uma superclasse e subclasse. Os Quadros são formas de representação de redes semânticas que, de acordo com COPPIN (2017), expressam a ideia de herança interligada por relações.

Os espaços por busca, conforme LUGER (2013), devem acompanhar os caminhos de um nó inicial até seu objetivo, pois esses caminhos levam a solução do problema.

As árvores semânticas é uma rede semântica que tem: Um nó raiz; nó predecessor e sucessor; folhas (nó sem sucessores) e são chamadas de alvo, e os alvos são busca bem sucedidas; ancestral, nó acima dele durante o caminho da árvore; descendente vem depois do nó em um caminho na árvore; caminho é a rota completa da árvore. (COPPIN, 2017). Na figura 1 abaixo demonstra um modelo de árvore de decisão.



Fonte: Araújo, Y. B. et al (2014)

De acordo com CARVALHO et al (2011), árvore de decisão é um grafo acíclico direcionado em que cada nó pode ser um nó de divisão, com dois ou mais sucessores, ou um nó folha. Uma árvore de decisão procura dividir problemas complexos em problemas mais simples. Já COPPIN (2017) diz que uma árvore de decisão utiliza um conjunto de valores de atributos e representa



uma decisão booleana. De acordo com COPPIN (2017), uma árvore de decisão indutiva envolve o uso de um conjunto de dados de treinamento para gerar uma árvore de decisão. Para realizar a divisão dos nós, é analisado as características em cada estágio da árvore, selecionando as características que tem maior ganho de informação, ou seja, redução da entropia. A entropia, de acordo com (CARVALHO et al, 2011), mede a aleatoriedade de uma variável aleatória.

A entropia, conforme COPPIN (2017), é calculada através da expressão:

$$H(S) = -p_1 \log_2 p_1 - p_0 \log_2 p_0$$

P1 = exemplos de proporção dos dados positivos.

P0 = exemplos de proporção dos dados negativos.

A entropia será 0 quando todos os exemplos forem positivos ou negativos. Enquanto que ela será 1 quando a metade dos exemplos forem positivos e negativos.

O ganho é a redução da entropia conforme na expressão abaixo.

$$G = E - \sum - \left| \frac{c1p+}{at} \right| * Ec1 - \left| \frac{c2p-}{at} \right| * Ec2$$

G é o ganho de informação, c1 = primeira característica, p+ = proporção positiva, Ec1 = Entropia primeira característica, c2 = segunda característica, p- = proporção negativa, Ec2 = Entropia segunda característica e at amostra total.

Porém um dos riscos que podem acontecer é o overfitting ou underfitting. Overfitting, segundo BROWNLEE (2016), refere-se quando o modelo de dados aprende muito bem os dados de treinamento e quando é aplicado aos novos dados não classifica corretamente, afetando negativamente a classificação das amostras. Enquanto o underfitting é exatamente o contrário, quando não consegue aprender e consequentemente não consegue classificar os dados.

Desse modo, o ideal é um ponto entre o overfitting e o underfitting que é antes do erro começar a aumentar e tiver capacidade de aprender tanto no conjunto de treino quanto no conjunto de dados de teste.



O problema de overfitting pode ser resolvido através das técnicas de reamostragem para estimar a precisão do modelo e a retenção do conjunto de dados de validação.

A técnica de reamostragem frequentemente utilizada, conforme BROWNLEE (2016), é o k-fold que permite treinar e testar o modelo em diferentes subconjuntos de dados de treinamento. Já a técnica de validação cruzada, de acordo com BROWNLEE (2016), é um padrão aplicado para estimar a precisão do modelo de dados não vistos.

METODOLOGIA

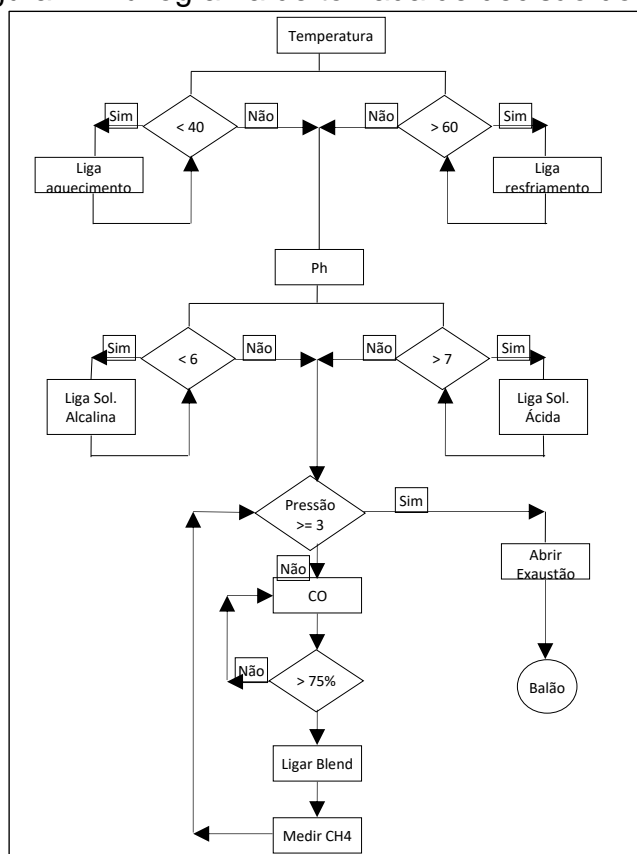
O desenvolvimento da pesquisa ocorreu por meio de pesquisa bibliográfica, que é desenvolvida com base em material já elaborado, constituído principalmente de livros e artigos científicos (GIL, 2002).

Todos os códigos em Python foram escritos na plataforma integrada de desenvolvimento PyCharm, disponível gratuitamente na internet e executados em um notebook pessoal rodando Windows 7 com processador Centrino e 2 Gbytes (GB) de memória RAM sem configurações especiais além da instalação do PyCharm.

As regras de decisão foram levantadas com profissionais especialistas em biodigestores e definidas conforme o fluxograma apresentado na figura 2.



Figura 2: Fluxograma de tomada de decisão dos sensores



Fonte: (FERREIRA, L. F, SANTOS, H. S., 2018)

Como resultado dessas regras, como visto na figura 2, foram estipuladas as condições de cada variável que favorecem a produção de biogás e estão resumidos no quadro 1 abaixo:

Quadro 1 – Condições para produção de Biogás

Variáveis	Valores
Ph	> 6 e < 7
Temperatura	< 40 e < 60
Monóxido Carbono	> 75ppm

Fonte: (FERREIRA, L. F, SANTOS, H. S., 2018)

Conforme o quadro 1 acima, para a produção do biogás, o ph da solução deve estar entre 6 e 7, a temperatura deve ser entre 40 e 60 graus celsius e o monóxido de carbono tem que ser maior do que 75 partes por milhões. Desse modo, cada registro da base de treinamento que não atendesse as restrições foram classificadas como “anormais”, caso todas as restrições fossem atendidas foram classificadas como “normais”.



Após o levantamento dos requisitos com os profissionais especialistas, partiu-se para a definição da técnica de machine learning que foi utilizada no projeto, onde foi selecionada a árvore de decisão.

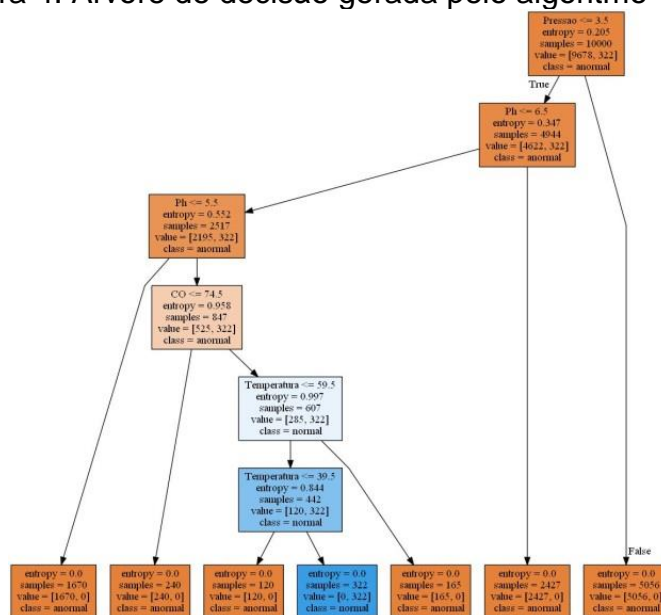
A árvore de decisão é uma técnica que se utiliza de treinamento supervisionado de modo que é necessário apresentar dados de treinamento pré-classificados. Portanto, foram criados 10.000 registros aleatórios pré-classificados utilizando o software proprietário Excel da empresa Microsoft. Estes registros foram salvos em um arquivo nomeado BD_Biogás.xlsx e este arquivo é composto por quatro colunas que apresentam os dados das variáveis ph, temperatura e monóxido de carbono.

De posse da base de treinamento pré-classificado, passou para o desenvolvimento do algoritmo que criou a árvore de decisão. Para desenvolver o algoritmo utilizou-se a linguagem de programação livre e multiplataforma Python e a IDE de desenvolvimento Spyder.

Para criar a árvore de decisão utilizou-se o arquivo de treinamento pré-classificado para gerar um dataframe utilizando a biblioteca open source Pandas patrocinada pela NumFocus, cuja é utilizada para Data Science. Este dataframe foi dividido em uma matriz composta pelos atributos previsores (variáveis ph, pressão, temperatura e monóxido de carbono) e um vetor com o atributo classe (coluna com a classificação de “anormal” ou “normal” de cada registro). Como o dataframe pronto, utilizou-se a biblioteca Sklearn (biblioteca de aprendizagem de máquina) que possui algoritmos implementados para classificação, regressão e agrupamento. Desta biblioteca foi utilizado o algoritmo de classificação árvore de decisão, onde foram passados os atributos previsores e o vetor classe para realizar o treinamento. Através deste treinamento foi gerada a árvore de decisão da figura 4 árvore de decisão gerada pelo algoritmo.



Figura 4: Árvore de decisão gerada pelo algoritmo



Fonte: (FERREIRA, L. F, SANTOS, H. S., 2018)

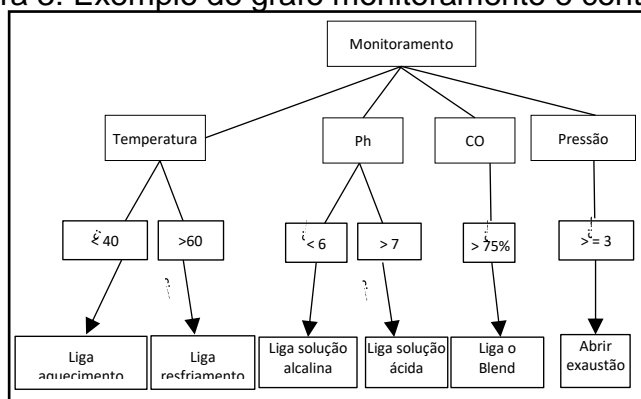
Após a realização do treinamento, foi inserido outra base de dados com 100 registros, em Excel, nomeado como leituras_biodigestor.xlsx. Como o biodigestor está em fase de implantação e não está gerando dados reais, realizou-se a simulação aleatória da leitura dos sensores. Essa base de dados foi passada para o algoritmo realizar a classificação e os resultados são abordados no capítulo 4 deste artigo.

Em paralelo ao processo de classificação realizada pela árvore de decisão é necessário realizar o monitoramento e controle das variáveis, pois quaisquer das variáveis que estejam fora das condições explanadas no quadro 1 deste referido artigo, comprometem todo o processo de geração do biogás.

Portanto elaboraram-se, em grafos, as tomadas de decisões conforme cada variável esteja fora das condições pré-definidas. Essas decisões irão atuar sobre os controles acoplados ao biodigestor.



Figura 3: Exemplo de grafo monitoramento e controle



Fonte: (FERREIRA, L. F, SANTOS, H. S., 2018)

O grafo apresentado na figura 3 foi utilizado para criar os algoritmos de monitoramento e controle dos atuadores acoplados ao biodigestor. Assim, quando o sensor de temperatura ler valores abaixo de 40° C o mesmo irá acionar o atuador que controla o aquecimento, em oposto, se o sensor de temperatura ler valores acima de 60° C o sistema irá acionar o controle de resfriamento. Passando para a próxima variável, o pH, se o sensor ler dados abaixo de 6 irá acionar o controle de solução alcalina, enquanto que se a leitura for acima de 7, será acionado o controle da solução ácida. Já quando o Monóxido de Carbono (CO) atingir 75 partes por milhão ou mais. o acionador deverá atuar sobre o Blend. E por fim, a válvula de segurança de pressão será acionado todo momento que a mesma for maior que 3 bar.



CONSIDERAÇÕES FINAIS

Devido o biodigestor estar na fase de implantação e ainda não produzir resultados reais, utilizou-se base de dados aleatórios, tanto para treinamento quanto para a classificação de novos dados, conforme mencionado na metodologia.

Diante o exposto, para verificar o resultado de precisão da classificação dos novos dados foi utilizado a classe Sklearn.metrics, o método `accuracy_score` da biblioteca Sklearn. Esse método compara os resultados da classe da base de treinamento com a previsão de classificação dos novos dados. O resultado é apresentado na Figura 5 que demonstra o percentual dos registros de classificação correta (acurácia ou confiança).

Figura 5: Nível de Confiança da classificação

<code>precisao</code>	<code>float64</code>	<code>1</code>	<code>0.93000000000000005</code>
-----------------------	----------------------	----------------	----------------------------------

Fonte: (FERREIRA, L. F, SANTOS, H. S., 2018)

Como é possível observar, o nível de confiança de classificação do algoritmo é de 93%, ou seja, de 100 leituras realizadas o algoritmo classificou corretamente 93 leituras.

Na matriz de confusão apresentado na figura 6 os valores binários 0 e 1 referem-se, respectivamente, 0 representam leituras classificadas como “anormais” e 1 representam as leituras classificadas como “normais”. Portanto, na matriz de confusão demonstrada na figura 6, podemos observar que há 97 leituras “anormais” e 3 leituras “normais”. Em relação as leituras “anormais” (97) temos que 93 dessas leituras foram classificadas corretamente como “anormal” e 4 foram classificadas incorretamente como “normal”. Enquanto as leituras “normais” (3) foram classificadas incorretamente como “anormais”.

Figura 6: Matriz de confusão

	0	1
0	93	4
1	3	0

Fonte: (FERREIRA, L. F, SANTOS, H. S., 2018)



Para verificar a precisão da classificação realizada pelo algoritmo realizou-se o cálculo somando as classificações corretas, ou seja, a soma na diagonal das coordenadas $(0,0) = 93$ + as coordenadas $(1,1) = 0$. Esse resultado divide pela soma dos 4 valores $(93 + 4 + 3 + 0 = 100)$. Portanto a precisão é $93 / 100 = 93 \%$ conforme apresentado na figura 5 onde foi calculado pelo algoritmo (logo o valor é mais preciso).

A sequência deste projeto será a integração entre o algoritmo escrito na linguagem de programação Python e a codificação em Arduino. Além dessa etapa, será implementado processamento paralelo para o monitoramento e controle, pois atualmente é sequencial. É necessário o processamento paralelo pois cada variável, de forma independente, pode comprometer todo o processo de produção do Biogás. E por fim, quando o biodigestor estiver implementado, será utilizado o algoritmo da árvore de decisão para realizar a classificação das leituras capturadas pelos sensores do biodigestor.



REFERÊNCIAS

- ALMEIDA, G. V. B. P., **Biodigestão anaeróbica na suinocultura**. 2008
- ALVES, S. M., MELO, C. F. M., WISNIEWSKI, A. Biogás; **Uma Alternativa de Energia no Meio Rural**. EMBRAPA: Centro de Pesquisa Agropecuária do Trópico Úmido. Belém – PA.1980. Disponível em: <https://www.infoteca.cnptia.embrapa.br/bitstream/doc/378021/1/Miscelanea4.pdf>. Acessado em 10/07/2018
- ARAÚJO, Y. B., MEDEIROS, A. R. C., MORAES, R. M., VIANNA, R. P. T. **Modelo de suporte à decisão aplicado à identificação de indivíduos não aderentes ao tratamento anti-hipertensivo**. Acessado em 18/08/2018.
- BROWNLEE, J. **Overfitting and Underfitting With Machine Learning Algorithms**. Disponível em: <https://machinelearningmastery.com/overfitting-and-underfitting-with-machine-learning-algorithms/> Acessado em 18/08/2018
- CARVALHO, A. C. P. L. F., FACELI, K., GAMA, J., LORENA, A. C. **Inteligência Artificial: Uma abordagem de Aprendizado de Máquina**. Rio de Janeiro: LTC, 2017.
- COPPIN, B. **Inteligência artificial**. Rio de Janeiro: LTC, 2017.
- CREMONEZ, P. A., FEIDEN, A., SANTOS, R. F., ROSSI, E., NADALETI, W. C., ANTONELLI, J. **Biodigestão anaeróbia no tratamento de águas residuárias de feculárias**. 2013.
- FERNANDES, D. M. **Biomassa e Biogás da Suinocultura**. Disponível em: <http://tede.unioeste.br/bitstream/tede/821/1/Dangela%20Maria%20Fernandes.pdf>. Acessado em 09/07/2018.
- FNR. **Guia Prático do Biogás**. Fachagentur Nachwachsende Rohstoffe. 5 ed. 2010.
- FUNDAÇÃO ARDUINO. **O que é Arduino?**. <https://www.arduino.cc/en/Guide/Introduction>. Acessado em 10/07/2018.
- GIL, Antonio Carlos. **Como Elaborar Projetos de Pesquisa**. 4. ed. São Paulo: Editora Atlas, 2002.
- GRANATYR, J. **Solucionador Geral de Problemas (GPS)**. IA Expert, 2016. Acessado em 18/08/2018
- KARLSSON, T., KONRAD, O., LUMI, M., SCHMEIER, N. P., MARDER, M., CASARIL, C. E., KOCH, F. F., PEDROSO, A. G. **Manual Básico de Biogás**. 1 ed. Univates. Lajeado - RS, 2014.



LUGER, G. F. Inteligência Artificial. 6. ed. - São Paulo - Pearson Education do Brasil, 2013.

NORVIG, P., RUSSELL, J. L. 1962. Inteligência Artificial ; tradução Regina Célia Simille. – Rio de Janeiro: Elsevier, 2013.

ROSA, J. L. G., Fundamentos da Inteligência Artificial. Rio de Janeiro: LTC, 2011.

SUZUKI, A. B. P. **Geração de Biogás utilizando cama de aviário e manipueira.** 2012.

WINROCK INTERNATIONAL BRASIL. Manual de Biodigestão.